
RELATÓRIO DE ANÁLISE DE DADOS

Processo Seletivo para Bolsas

Comparação de Perfis Demográficos:

Candidatos Selecionados vs. Não Selecionados

Elaborado por:	Sabrina
Data do Relatório:	11/04/2026
Período:	Processo Seletivo 2026
Total de Candidatos:	3.000
Selecionados:	1927 (64.2%)
Não Selecionados:	1073 (35.8%)

SUMÁRIO

1. Resumo Executivo
 2. Introdução e Metodologia
 3. Visão Geral dos Dados
 4. Análise por Sexo
 5. Análise por Idade
 6. Análise por Orientação Sexual
 7. Análise por Raça/Cor – Achado Crítico
 8. Análise por Deficiência
 9. Análise Interseccional (Raça × Sexo)
 10. Resumo dos Testes Estatísticos
 11. Conclusões e Recomendações
 12. Análises Complementares Sugeridas
- Apêndice: Metodologia Detalhada

1. RESUMO EXECUTIVO

Este relatório apresenta uma análise descritiva e inferencial dos dados de **3000** candidatos que participaram de um processo seletivo para bolsas. O objetivo é identificar se existem diferenças significativas no perfil demográfico de candidatos selecionados e não selecionados, utilizando técnicas estatísticas adequadas para cada tipo de variável.

Principais achados:

- Taxa de seleção geral:** 64.2% dos candidatos foram selecionados (1927 de 3000).
- Raça/Cor (achado crítico):** Identificou-se associação estatisticamente significativa entre raça/cor e a probabilidade de seleção ($\chi^2 = 98.95$, $p < 0,001$, V de Cramér = 0.182). As taxas de seleção variam de 33.3% a 79.0% conforme o grupo racial, diferença de 45.7 pontos percentuais.
- Sexo, orientação sexual, idade e deficiência:** Não foram encontradas associações estatisticamente significantes com a seleção ($p > 0,05$ em todos os testes), indicando que essas variáveis não diferenciam selecionados de não selecionados nas condições deste processo.
- Recomendação:** Investigar os critérios de seleção para compreender as disparidades raciais observadas e avaliar a necessidade de intervenções para garantir equidade no processo.

2. INTRODUÇÃO E METODOLOGIA

Contexto: O presente relatório foi elaborado no âmbito de uma consultoria em análise de dados, com o objetivo de descrever e comparar o perfil de candidatos selecionados e não selecionados em um processo seletivo para bolsas. A base contém 3000 registros com as seguintes variáveis: **Id_aluno**, **Selecionado**, **Sexo**, **OrientacaoSexual**, **Idade**, **Raça-cor** e **Deficiência**.

Metodologia:

- **Análise descritiva:** Frequências absolutas e relativas, medidas de tendência central e dispersão, tabelas de contingência e visualizações gráficas.
- **Análise inferencial:**
 - **Teste t de Student** para comparação de médias de idade entre grupos (variável contínua);
 - **Teste U de Mann-Whitney** como alternativa não paramétrica para idade;
 - **Teste Qui-Quadrado de Pearson** para associação entre variáveis categóricas e seleção;
 - **V de Cramér** como medida de tamanho de efeito para variáveis categóricas.
- **Nível de significância:** $\alpha = 0,05$. Valores p menores que 0,05 indicam significância estatística.
- **Software:** Python 3.13, com as bibliotecas pandas, scipy, matplotlib, seaborn e ReportLab.


3. VISÃO GERAL DOS DADOS

A base de dados contém **3000** candidatos, dos quais **1927 (64.2%)** foram selecionados e **1073 (35.8%)** não foram selecionados. A tabela e o gráfico a seguir apresentam essa distribuição.

Tabela 1 – Distribuição do resultado do processo seletivo

Status	n	%
Selecionados	1927	64.2%
Não Selecionados	1073	35.8%
Total	3000	100,0%

Figura 1 – Distribuição geral e taxa de seleção por sexo



4. ANÁLISE POR SEXO

Tabela 2 – Distribuição e taxa de seleção por sexo

Sexo	Selecionados	Não Selecionados	Total	Taxa (%)
F	1015	559	1574	64.5%
M	912	514	1426	64.0%

Teste Chi-Quadrado: $\chi^2 = 0.0699$, gl = 1, p = 0.7914 (n.s.), V de Cramér = 0.0048.

Interpretação: A taxa de seleção de mulheres (64.5%) e homens (64.0%) é muito semelhante, com diferença de apenas 0.5 pontos percentuais. O teste qui-quadrado confirma que **não há associação estatisticamente significativa** entre sexo e resultado da seleção (p = 0.7914). O V de Cramér (0.0048) indica tamanho de efeito desprezível. **Conclusão:** o sexo do candidato não é um fator diferenciador no processo seletivo analisado.

5. ANÁLISE POR IDADE

Tabela 3 – Estatísticas descritivas de idade por grupo

Estatística	Selecionados	Não Selecionados
Média	22.3	22.4
Desvio Padrão	4.3	4.9
Mínimo	17.0	17.0
1º Quartil	20.0	19.0
Mediana	21.0	21.0
3º Quartil	24.0	24.0
Máximo	61.0	62.0

Figura 2 – Distribuição de idade por status de seleção





Figura 3 – Histograma de idade sobreposto



Teste T de Student: $t = -0.3388$, $p = 0.7348$ (n.s.).

Teste U de Mann-Whitney: $U = 1061085.0$, $p = 0.2280$ (n.s.).

Interpretação: A idade média dos selecionados (22.3 anos, DP = 4.3) é muito próxima à dos não selecionados


(22.4 anos, DP = 4.9). Tanto o teste paramétrico (teste t) quanto o não paramétrico (Mann-Whitney) indicam que **não há diferença estatisticamente significativa** na idade entre os dois grupos. Os boxplots e histogramas confirmam sobreposição quase completa das distribuições. **Conclusão:** a idade não é um fator que diferencia selecionados de não selecionados.

6. ANÁLISE POR ORIENTAÇÃO SEXUAL

Tabela 4 – Distribuição e taxa de seleção por orientação sexual

Orientação Sexual	Sel.	Não Sel.	Total	Taxa (%)
Outro	12	4	16	75.0%
Homossexual	184	90	274	67.2%
Pansexual	62	33	95	65.3%
Bissexual	400	220	620	64.5%
Prefiro não responder	92	52	144	63.9%
Heterossexual	1177	674	1851	63.6%

Figura 4 – Taxa de seleção por orientação sexual



Teste Chi-Quadrado: $\chi^2 = 2.2334$, gl = 5, p = 0.8160 (n.s.), V de Cramér = 0.0273.

Interpretação: Apesar de alguma variação nas taxas de seleção entre categorias de orientação sexual (de 63.6% a 75.0%), o teste qui-quadrado revela que **não há associação estatisticamente significativa** entre orientação sexual e seleção. O V de Cramér (0.0273) confirma efeito negligenciável. Nota: algumas categorias possuem poucos representantes, o que reduz o poder estatístico para detectar diferenças reais, caso existam. **Conclusão:** a orientação sexual não diferencia significativamente os grupos neste processo seletivo.


7. ACHADO CRÍTICO: DISPARIDADES POR RAÇA/COR

ATENÇÃO: Esta seção apresenta o principal achado da análise: a variável raça/cor é a única que apresenta associação estatisticamente significativa com o resultado da seleção.

Tabela 5 – Distribuição e taxa de seleção por raça/cor

Raça/Cor	Selecionados	Não Selecionados	Total	Taxa (%)
Preta	263	70	333	79.0%
Parda	636	244	880	72.3%
Não informada	85	40	125	68.0%
Branca	909	687	1596	57.0%
Amarela	33	30	63	52.4%
Indígena	1	2	3	33.3%

Figura 5 – Taxa de seleção por raça/cor



Teste Chi-Quadrado: $\chi^2 = 98.95$, $gl = 5$, $p < 0,001$ ***, V de Cramér = 0.182.

Interpretação detalhada:

- A variável raça/cor apresenta **associação estatisticamente significativa** com o resultado da seleção, sendo a única variável do estudo com esse resultado.
- A **maior taxa de seleção** é observada entre candidatos de raça/cor **Preta** (79.0%), enquanto a **menor taxa** ocorre entre candidatos **Indígena** (33.3%).
- O **gap máximo** entre grupos é de **45.7 pontos percentuais**, uma diferença substancial que merece investigação aprofundada.
- O V de Cramér (0.182) indica um efeito de magnitude pequena, mas que é prático e estatisticamente relevante no contexto de políticas de equidade.

Possíveis explicações para a disparidade:

- Crítérios meritocráticos:** se os critérios de seleção incluem desempenho acadêmico ou profissional, diferenças socioeconômicas entre grupos raciais podem explicar parte da variação.
- Vieses no processo:** vieses conscientes ou inconscientes por parte dos avaliadores.
- Efeito de composição:** diferenças na distribuição de outras variáveis relevantes (como renda, escolaridade dos pais ou região de origem) que não estão disponíveis na base.

4. **Políticas afirmativas:** caso existam critérios de ação afirmativa, as taxas podem refletir uma compensação intencional de desigualdades históricas.

8. ANÁLISE POR DEFICIÊNCIA

Tabela 6 – Distribuição e taxa de seleção por status de deficiência

Deficiência	Selecionados	Não Selecionados	Total	Taxa (%)
Com deficiência	74	40	114	64.9%
Sem deficiência	1853	1033	2886	64.2%

Figura 6 – Prevalência de deficiência e taxa de seleção





Figura 7 – Taxa de seleção por tipo de deficiência




Teste Chi-Quadrado: $\chi^2 = 0.0030$, gl = 1, p = 0.9565 (n.s.), V de Cramér = 0.0010.

Interpretação: Do total de candidatos, 114 (3.8%) reportaram ter algum tipo de deficiência. A taxa de seleção entre candidatos com deficiência (64.9%) e sem deficiência (64.2%) é próxima, com diferença de 0.7 p.p. O teste qui-quadrado confirma que **não há associação significativa** entre status de deficiência e seleção. **Conclusão:** ter ou não deficiência não afeta a probabilidade de seleção neste processo.

9. ANÁLISE INTERSECCIONAL (RAÇA × SEXO)

Para compreender melhor as disparidades observadas na variável raça/cor, realizamos uma análise interseccional cruzando raça/cor com sexo. O mapa de calor a seguir apresenta as taxas de seleção para cada combinação desses dois atributos. Esta abordagem permite verificar se as disparidades raciais são consistentes entre homens e mulheres ou se há interações relevantes.

Figura 8 – Mapa de calor: taxa de seleção por raça/cor e sexo



Interpretação: O mapa de calor revela que as disparidades raciais observadas são consistentes entre ambos os sexos. Os grupos com maiores e menores taxas de seleção mantêm-se relativamente na mesma ordem para homens e mulheres, sugerindo que o efeito da variável raça/cor opera de forma independente do sexo. Essa consistência fortalece a conclusão de que raça/cor é, de fato, o principal fator associado a diferenças no processo seletivo.

Nota metodológica: Em análises interseccionais, é importante considerar que os tamanhos amostrais para combinações específicas (por exemplo, mulheres indígenas) podem ser pequenos, o que limita a confiabilidade pontual dessas estimativas. Para inferências mais robustas sobre subgrupos, seria necessária uma amostra maior ou uso de modelos de regressão logística multivariada.

10. RESUMO DOS TESTES ESTATÍSTICOS

A tabela abaixo consolida todos os testes inferenciais realizados, permitindo uma visão panorâmica de quais variáveis apresentam associação significativa com o resultado do processo seletivo.

Tabela 7 – Consolidação dos testes estatísticos

Variável	Teste	Estatística	p-valor	Tam. Efeito	Signif.?
Idade	Teste T	-0.3388	0.7348	–	Não
Idade	Mann-Whitney	1061085	0.2280	–	Não
Sexo	Chi-Quadrado	0.0699	0.7914	V=0.0048	Não
Orient. Sexual	Chi-Quadrado	2.2334	0.8160	V=0.0273	Não
Raça/Cor	Chi-Quadrado	98.95	0.000000	V=0.182	Sim ***
Deficiência	Chi-Quadrado	0.0030	0.9565	V=0.0010	Não

Legenda: *** $p < 0,001$; ** $p < 0,01$; * $p < 0,05$; n.s. = não significativa. V = V de Cramér (tamanho de efeito para variáveis categóricas).

Síntese dos resultados inferenciais:

Entre as cinco variáveis analisadas, apenas **raça/cor** apresenta associação estatisticamente significativa com o status de seleção ($p < 0,001$). Todas as demais variáveis — idade, sexo, orientação sexual e deficiência — não apresentam diferenças estatisticamente significantes entre candidatos selecionados e não selecionados.

É importante ressaltar que a ausência de significância estatística não implica necessariamente que essas variáveis não tenham nenhuma relação com a seleção: pode haver efeitos pequenos que o tamanho amostral não foi suficiente para detectar, ou efeitos mascarados por variáveis confundidoras não disponíveis na base de dados.

11. CONCLUSÕES E RECOMENDAÇÕES

11.1 Conclusões

- Raça/Cor é o principal fator diferenciador:** A análise revelou que, entre todas as variáveis demográficas disponíveis, apenas raça/cor apresenta associação estatisticamente significativa com a seleção ($\chi^2 = 98.95$, $p < 0,001$). A diferença nas taxas de seleção entre grupos raciais atinge 45.7 pontos percentuais, o que é tanto estatisticamente quanto praticamente significativo.
- Equidade em outras dimensões:** As análises indicam que o processo seletivo não apresenta disparidades significantes em relação a sexo, orientação sexual, faixa etária ou status de deficiência. Isso indica equidade nessas dimensões.
- Análise interseccional confirma o achado:** As disparidades raciais são consistentes entre homens e mulheres, reforçando que raça/cor é o fator determinante, sem interação relevante com gênero.
- Necessidade de investigação complementar:** Os dados disponíveis não permitem determinar se as disparidades raciais decorrem de vieses no processo ou de diferenças nas qualificações objetivas dos candidatos. Informações adicionais são necessárias.

11.2 Recomendações

Curto prazo:

- Revisar os critérios de seleção para identificar possíveis pontos de viés implícito.
- Analisar se variáveis de desempenho (notas, provas, entrevistas) explicam as disparidades raciais.
- Considerar implementação de processos de avaliação cega (blind review).

Médio prazo:

- Conduzir análises multivariadas (regressão logística) controlando por variáveis socioeconômicas.
- Incorporar treinamento sobre vieses inconscientes para avaliadores do processo.
- Estabelecer metas e indicadores de diversidade para monitoramento contínuo.

Longo prazo:

- Implementar políticas de ação afirmativa, se apropriado ao contexto institucional.
- Criar um banco de dados longitudinal para acompanhar a evolução das disparidades ao longo dos anos.
- Documentar e comunicar transparentemente as políticas de equidade e inclusão.

12. ANÁLISES COMPLEMENTARES SUGERIDAS

A presente análise foi limitada às variáveis demográficas disponíveis. Caso houvesse acesso a informações adicionais, as seguintes análises poderiam aprofundar significativamente a compreensão dos resultados do processo seletivo:

- 1. Regressão Logística Multivariada:** Modelar a probabilidade de seleção em função de todas as variáveis demográficas simultaneamente, permitindo isolar o efeito individual de cada variável controlando pelas demais. Adicionalmente, incluir termos de interação (ex.: raça × sexo) para verificar efeitos cruzados.
- 2. Análise de Desempenho Acadêmico:** Se disponíveis notas, coeficientes de rendimento ou pontuações de provas, seria possível realizar ANOVA e verificar se diferenças de desempenho explicam as disparidades observadas na seleção por raça/cor.
- 3. Variáveis Socioeconômicas:** Renda familiar, escolaridade dos pais, região de origem e tipo de escola (pública/privada) são variáveis que tipicamente estão correlacionadas com raça/cor no Brasil. Sua inclusão no modelo permitiria avaliar em que medida as disparidades raciais são mediadas por fatores socioeconômicos.
- 4. Análise Longitudinal:** Com dados de múltiplos processos seletivos, seria possível avaliar tendências temporais e o impacto de eventuais mudanças nas políticas de seleção.
- 5. Propensity Score Matching:** Técnica que permite comparar candidatos com perfis semelhantes em outras variáveis, isolando o efeito específico de raça/cor sobre a seleção.
- 6. Análise do Texto de Deficiência:** A variável "Deficiência" contém tipos específicos de deficiência. Uma análise textual mais fina poderia identificar se tipos específicos de deficiência estão associados a maiores ou menores taxas de seleção.
- 7. Análise Qualitativa:** Entrevistas e grupos focais com candidatos selecionados e não selecionados para compreender percepções sobre equidade no processo.

APÊNDICE – METODOLOGIA DETALHADA

Fonte de dados: Base de dados ProcessoSeletivo.csv contendo 3000 registros.

Variáveis analisadas:

- **Variável dependente:** Selecionado (Sim/Não) – variável categórica binária.
- **Variáveis independentes:**
 - Idade: variável contínua (anos completos);
 - Sexo: F (feminino), M (masculino);
 - Orientação Sexual: Bissexual, Heterossexual, Homossexual, Pansexual, Outro, Prefiro não responder;
 - Raça/Cor: Amarela, Branca, Indígena, Parda, Preta, Não informada;
 - Deficiência: tipo de deficiência ou "Não possuo" (recodificada em Sim/Não).

Testes estatísticos empregados:

- **Teste t de Student (bilateral):** Compara médias de idade entre selecionados e não selecionados. Hipótese nula: as médias são iguais. Pressupõe normalidade aproximada (razoável para n grande, pelo Teorema Central do Limite).
- **Teste U de Mann-Whitney:** Alternativa não paramétrica ao teste t, não assume distribuição específica. Testa se as distribuições de idade são iguais entre os dois grupos.
- **Teste Qui-Quadrado de Pearson:** Avalia independência entre duas variáveis categóricas. Hipótese nula: não há associação entre a variável e o resultado da seleção.
- **V de Cramér:** Medida de associação entre variáveis categóricas nominais, variando de 0 (sem associação) a 1 (associação perfeita). Valores menores que 0,1 indicam efeito desprezível; 0,1–0,3 efeito pequeno; 0,3–0,5 moderado; acima de 0,5 grande.

Nível de significância: $\alpha = 0,05$ (5%). Resultados com $p < 0,05$ são considerados estatisticamente significantes.

Ferramentas: Python 3.13, pandas 3.0.2, scipy, matplotlib, seaborn, ReportLab.

Limitações:

- Análise restrita às variáveis disponíveis na base; variáveis confundidoras relevantes podem não estar contempladas.
- Não é possível inferir causalidade a partir de estudos observacionais — apenas associação.
- Alguns subgrupos (ex.: categorias de orientação sexual ou tipos de deficiência) possuem poucos representantes, limitando o poder dos testes.